Felix Möller

Machine Learning • Computer Vision • LLM & RAG

Erfurt, Deutschland
felixmoeller@felixmoeller.me • felixmoeller.me, LinkedIn

Informatiker (M.Sc., TU Ilmenau, Note 1,3), der Deep-Learning-Modelle in PyTorch trainiert und evaluiert und LLM-basierte Anwendungen mit FastAPI und React entwickelt. Bei der BMW Group einen Klassifikator für Fahrzeugfehler auf baumstrukturierte Daten erweitert (bis zu +2 Prozentpunkte F1) und die Kalibrierungsmethode MetaCal evaluiert, mit einem um rund eine Größenordnung niedrigeren Kalibrierungsfehler als der bestehende Ansatz. Masterarbeit (Note 1,0) zur effizienten Multi-View-Objekterkennung: rund 88 % weniger geschätzter Rechenaufwand auf Videodaten bei vergleichbarer Genauigkeit. Entwickelt und betreibt einen RAG-Assistenten, live auf felixmoeller.me, und bringt 20 Monate Full-Stack-Entwicklung in einem agilen Team mit. Sucht eine Vollzeitstelle in ML- und KI-Engineering, Data Science oder Computer Vision; umzugsbereit innerhalb Deutschlands oder remote.

Kernkompetenzen

- **Machine Learning & Deep Learning**: Python, PyTorch, PyTorch Lightning, scikit-learn, Pandas, NumPy, Matplotlib, Plotly; Set Transformer, Transfer- und Teacher-Student-Learning, Wahrscheinlichkeitskalibrierung; systematische Evaluation mit Ablationsstudien, wiederholten Läufen und balancierten Metriken; Experiment-Tracking mit Weights & Biases, Konfiguration mit Hydra.
- **Computer Vision**: CNNs (ConvNeXt, EfficientNet) mit torchvision, Multi-View-Bild- und Videoklassifikation, Frame- und Ansichtsauswahl für effiziente Inferenz, Datenaugmentierung (RandAugment), synthetische Bildstörungen (Unschärfe, Rauschen, Verdeckung) für Robustheit, OpenCV.
- **Generative KI & LLM-Anwendungen**: Retrieval-Augmented Generation (RAG) mit der Claude API (Quellenangaben, Prompt Caching, System-Prompts, Fallback-Modell), hybride lexikalische und semantische Suche (BM25 + mehrsprachige Embeddings, Reciprocal Rank Fusion), LLM-Evals, Schutz vor Prompt Injection; agentisches Programmieren mit Claude Code.
- **Backend & Deployment**: FastAPI, Pydantic, Server-Sent Events; Linux-Serverbetrieb (systemd, Caddy), Deploy-Skript mit Health-Checks, Uptime-Monitoring, GitHub Actions, Vercel; AWS (S3, SageMaker); Docker (in Einarbeitung, Microservice-Nebenprojekt).
- **Softwareentwicklung & Daten**: Java, JSF/PrimeFaces, JavaScript/React; SQL, PostgreSQL, Snowflake, Streamlit; Tests mit pytest, JUnit und Selenium; Scrum, Git, Jira.

Berufserfahrung

- **BMW Group** **München**
  Praktikant Data Analytics (Machine Learning) *04/2025 - 08/2025*
  KI-Modell zur Ursachenklassifikation von Fahrzeugfehlern aus Werkstattdaten. Python, PyTorch, Pandas, SQL, Snowflake, AWS.
  - Klassifikator auf baumstrukturierte JSON-Daten erweitert (rekursiver Set Transformer, PyTorch Nested Tensors ohne Padding): bis zu +2 Prozentpunkte F1 in betroffenen Anwendungsfällen
  - Kalibrierungsmethoden (BBQ, ENIR, MetaCal) mit der bestehenden isotonischen Regression verglichen; MetaCal implementiert (Expected Calibration Error um rund eine Größenordnung niedriger) und einen eigenen MLP-Kalibrator mit differenzierbarem ECE-Loss gebaut
  - Streamlit-Dashboard der Analysten auf Snowflake von Grund auf neu aufgebaut: änderungsbewusstes Caching und leichtgewichtige Zeilenmarkierungen beseitigten Wartezeiten von mindestens 5 Sekunden nach jeder Interaktion
  - Computer-Vision-Integration prototypisch umgesetzt (Zero-Shot-Bildkategorisierung, kategoriespezifische EfficientNetV2-S-Embeddings); das Team stellte die Entwicklung ein, da nur rund 1 % der Fälle Bilder enthielten
  - Ergebnisse dem Team mit Folien, Whiteboard und Live-Demos präsentiert

- **IBYKUS AG** **Erfurt**
  Werkstudent Webentwicklung (Full-Stack Java) *08/2023 - 03/2025*
  E-Government-Webportal zur Verwaltung öffentlicher Fördermittel, Scrum-Team. Java, JSF/PrimeFaces, JavaScript, SQL, PostgreSQL, Selenium, JUnit.
  - Frontend- und Backend-Features entwickelt, u. a. Teilprojekte für das Agrarumwelt-Förderprogramm HALM2 (Hessen)
  - Frontend-Taskforce geleitet: barrierearmer mobiler Prototyp und Frontend-Templates, die Backend-Entwickler wiederverwendeten
  - Brute-Force-Testframework für Formularvalidierungen entwickelt, das den Browser per Selenium steuert: 100 % Testabdeckung aller Formulare der Anwendung
  - Unit- und Integrationstests geschrieben, Bugs behoben und Praktikanten eingearbeitet

Ausbildung

- **Technische Universität Ilmenau** **Ilmenau**
  M.Sc. Informatik, Note 1,3 *04/2024 - 05/2026*
  Masterarbeit (Note 1,0): „Learning to Select Informative Views for Efficient Multi-View Object Recognition“. Zweistufige PyTorch-Pipeline entworfen: Ein leichtgewichtiger Frame-Scorer (EfficientNet Lite 0), im Teacher-Student-Verfahren auf kalibrierten Klassifikator-Konfidenzen trainiert, wählt die informativsten Frames für ein Multi-View-CNN (ConvNeXt Tiny). Evaluiert auf vier Datensätzen: rund 88 % weniger geschätzter Rechenaufwand auf Videodaten bei vergleichbarer Balanced Accuracy (höchstens 0,1 Prozentpunkte Verlust); 97 % Recall für beschädigte Frames.
- **Technische Universität Ilmenau** **Ilmenau**
  B.Sc. Informatik, Note 1,8 *10/2020 - 06/2024*

Projekte

- **felixmoeller.me**
  Portfolio-Website mit KI-Assistent *10/2026 - heute*
  Eigenprojekt, entwickelt mit Claude Code. Python, FastAPI, Claude API, RAG, React, pytest.
  - KI-Assistent entworfen, der Fragen von Recruitern mit Quellenangaben beantwortet: hybride Suche aus BM25 und mehrsprachigen Embeddings, fusioniert per Reciprocal Rank Fusion, Antworten per Server-Sent Events gestreamt
  - Abgesichert durch HMAC-signierten Chatverlauf gegen Prompt Injection, Rate Limits, Tagesbudget und Pydantic-Eingabevalidierung; DSGVO-konform (kein IP-Logging); rund 100 pytest-Tests plus LLM-Evals mit Fangfragen
  - Backend-Betrieb auf eigenem Linux-Server (systemd, Caddy) mit Deploy-Skript inkl. Health-Check und Uptime-Monitoring; zweisprachiges React-Frontend; Lebenslauf als Code per GitHub Actions

Sprachen

- Deutsch (Muttersprache), Englisch (C1, fließend), Chinesisch (Grundkenntnisse, HSK 1).

Referenzen

- Auf Anfrage erhältlich.